Clasificarea Calitatii Vinului Rosu

pe baza proprietatilor fizico-chimice

Proiect final — Curs Big Data

Cosma Simona & Cleescu Alexandra

Dataset: Wine Quality Dataset (Kaggle)

1. Introducere si selectia datelor

Pentru acest proiect am ales sa lucram pe o problema din domeniul industriei alimentare, mai exact clasificarea calitatii vinului rosu. Ideea de baza este destul de simpla: un vin poate fi evaluat chimic in laborator, si intrebarea este daca acele masuratori pot prezice daca vinul va fi considerat bun sau nu de catre degustatori. In practica, evaluarea manuala e scumpa si subiectiva — implica degustatori specializati, timp si costuri semnificative — asa ca un model automat antrenat pe date de laborator ar putea fi o alternativa utila.

Setul de date ales este Wine Quality Dataset, disponibil pe Kaggle si pe UCI Machine Learning Repository. A fost creat de Cortez et al. (2009) pe baza unor probe de vin Vinho Verde din Portugalia. Contine 1.143 de inregistrari, fiecare reprezentand un vin descris prin 11 caracteristici chimice si un scor de calitate acordat de experti pe o scala de la 3 la 8.

Am ales acest dataset din mai multe motive. In primul rand era disponibil si nu fusese luat de alta echipa. In al doilea rand, toate variabilele sunt numerice, ceea ce simplifica mult preprocesarea. In al treilea rand, problema e clara, bine definita si usor de explicat, ceea ce ajuta la interpretarea rezultatelor.

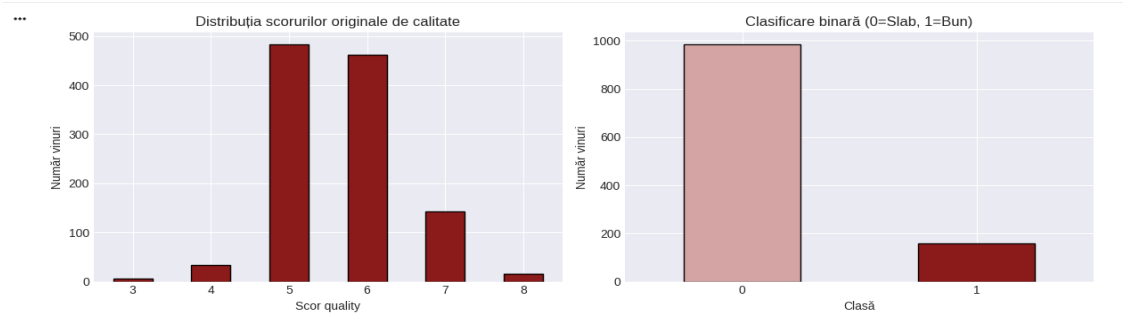
Descrierea caracteristicilor

Cele 11 variabile de intrare masoara proprietati chimice ale vinului: aciditate fixa, aciditate volatila, acid citric, zahar rezidual, cloruri, dioxid de sulf liber, dioxid de sulf total, densitate, pH, sulfati si continut de alcool. Toate sunt numerice continue, ceea ce inseamna ca nu au fost necesare transformari speciale pentru tipul de date.

Definirea variabilei tinta

Scorul original de calitate (3-8) a fost transformat intr-o variabila binara: vinurile cu scor 7 sau 8 sunt considerate bune (clasa 1), restul slabe (clasa 0). Pragul de 7 a fost ales pentru ca reprezinta limita de jos a categoriei superioare in sistemul de notare folosit de experti. Distributia scorurilor originale arata ca marea majoritate a vinurilor primesc scoruri de 5 sau 6, scorurile extreme fiind rare.

Dupa binarizare rezulta un dezechilibru semnificativ: 984 de vinuri slabe (86.1%) si 159 bune (13.9%). Acesta este un aspect important care va influenta atat alegerea metricilor de evaluare, cat si interpretarea rezultatelor. Figura 1 ilustreaza distributia scorurilor originale si clasificarea binara rezultata.




```
Distribuție absolută:
quality_binary
0    984
1    159
Name: count, dtype: int64

Distribuție procentuală:
quality_binary
0    0.861
1    0.139
Name: proportion, dtype: float64
```

Figura 1. Distributia scorurilor de calitate (stanga) si clasificarea binara (dreapta).

2. Preprocesarea datelor

Valori lipsa

Prima verificare a fost cautarea valorilor lipsa. Rezultatul a aratat ca setul de date este complet — nicio coloana nu contine valori nule. Prin urmare, nu a fost necesara nicio imputare sau eliminare de inregistrari, ceea ce simplifica semnificativ aceasta etapa a procesului KDD.

Detectarea si tratarea outlierilor

Am vizualizat distributia fiecarei variabile cu boxplot-uri (Figura 2). Se observa ca mai multe caracteristici au valori extreme, in special clorurile si zaharul rezidual. De exemplu, majoritatea vinurilor au continut de cloruri in jur de 0.07-0.09, dar exista cateva cu valori de peste 0.4, ceea ce sugereaza fie masuratori atipice, fie vinuri cu defecte evidente.

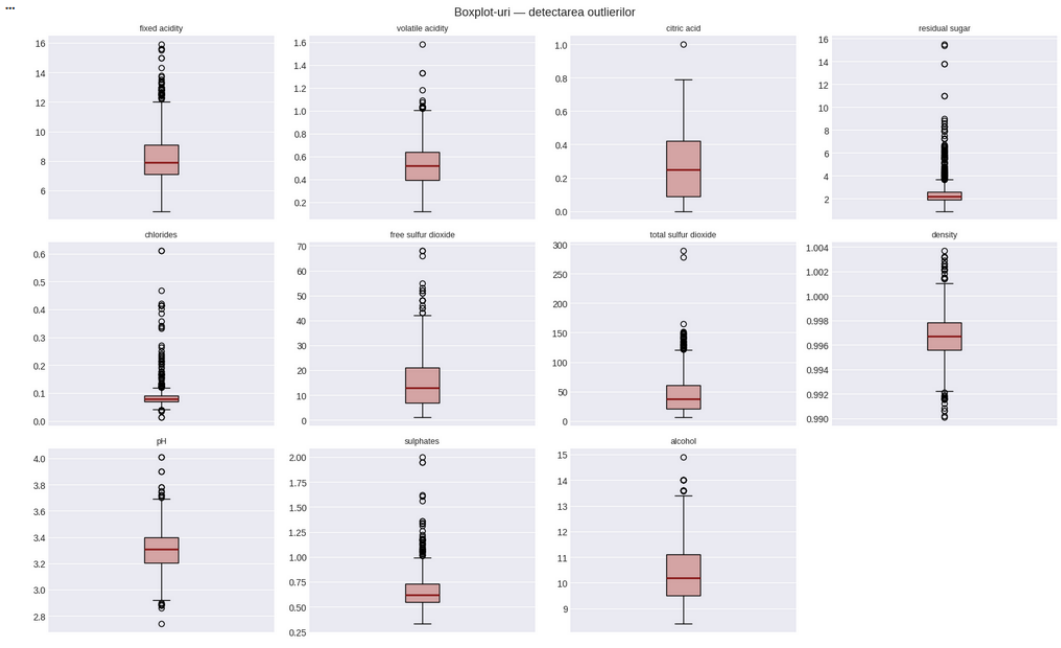


Figura 2. Boxplot-uri pentru toate cele 11 caracteristici. Punctele reprezinta outlieri detectati prin metoda IQR.

Pentru tratarea outlierilor am ales Winsorization: valorile de sub percentila 5% si de peste percentila 95% sunt inlocuite cu valorile de la acele limite. Avantajul fata de eliminarea randurilor este ca nu pierdem nicio inregistrare — toate cele 1.143 de vinuri raman in dataset. Dezavantajul este ca modificam valorile reale, dar influenta asupra distributiei generale este minima si justificata in contextul imbunatatirii stabilitatii modelelor.

Analiza corelatiilor

Am calculat matricea de corelatie Pearson pentru a intelege relatiile dintre variabile (Figura 3). Cel mai important rezultat este ca alcoolul are cea mai puternica corelatie cu scorul de calitate (r = 0.494), urmat de aciditatea volatila cu o corelatie negativa de -0.403 — vinurile cu aciditate volatila mai mare tind sa fie de calitate mai proasta — si sulfati cu 0.357. Variabilele pH si zaharul rezidual au corelatie aproape zero cu calitatea (0.058 si 0.037).

Nu am gasit colinearitati severe intre predictori, nicio pereche nu depaseste r = 0.7 in valoare absoluta, deci nu am eliminat nicio variabila pe aceasta baza.

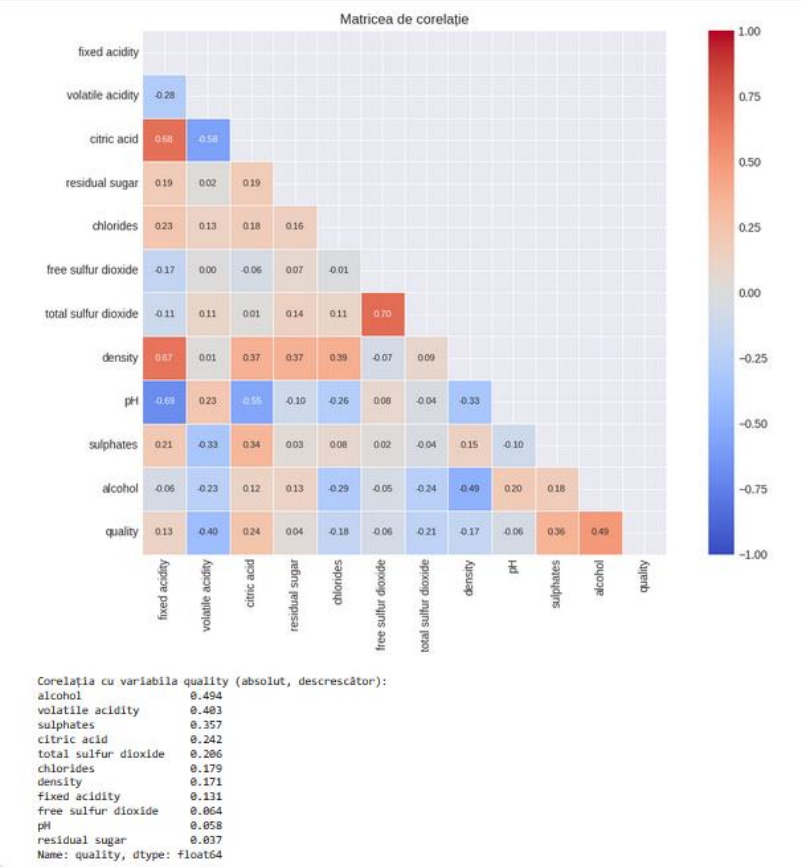


Figura 3. Matricea de corelatie Pearson. Valorile in rosu indica corelatie pozitiva, cele in albastru negativa.

3. Transformarea datelor

Impartirea datelor

Datele au fost impartite in 80% pentru antrenare (914 exemple) si 20% pentru testare (229 exemple). Am folosit parametrul stratify=y la impartire, care garanteaza ca proportia de vinuri bune este aproximativ aceeasi in ambele seturi. Aceasta este importanta in cazul nostru tocmai din cauza dezechilibrului de clase — fara stratificare, am risca ca setul de test sa contina proportional mai multe sau mai putine vinuri bune, ceea ce ar da o imagine distorsionata a performantei reale. Verificarea a confirmat: 13.89% vinuri bune in train si 13.97% in test.

Standardizarea

Variabilele au scale complet diferite — dioxidul de sulf total ajunge la 289, in timp ce densitatea variaza intr-un interval de ordinul 0.01. Fara standardizare, un model ca regresia logistica ar fi dominat de variabilele cu valori mari, nu pentru ca ar fi mai importante, ci pur si simplu pentru ca au numere mai mari.

Am aplicat StandardScaler, care transforma fiecare variabila sa aiba media 0 si deviatia standard 1. Un aspect esential: scaler-ul a fost antrenat exclusiv pe setul de train folosind fit_transform, iar pe setul de test a fost

aplicat doar transform, fara reantrenare. Daca am fi aplicat fit_transform pe tot dataset-ul, modelul ar fi vazut indirect informatii despre distributia datelor de test in timpul antrenarii, ceea ce ar fi dus la estimari de performanta artificiale mai bune (data leakage).

4. Selectia si antrenarea modelelor

Am antrenat trei algoritmi care acopera un spectru de la simplu la complex. Alegerea nu a fost intamplatoare — am vrut un model liniar ca referinta, un model de ansamblu bazat pe bagging si unul bazat pe boosting, pentru a putea compara abordari fundamental diferite si a vedea concret cu cat castiga complexitatea.

Logistic Regression

Regresia logistica e modelul cel mai simplu, ales ca baseline. Calculeaza o combinatie liniara a caracteristicilor si aplica o functie sigmoida pentru a obtine o probabilitate. Daca probabilitatea depaseste 0.5, vinul e clasificat ca bun. Este un model liniar, deci presupune ca frontiera de decizie dintre clase poate fi reprezentata ca un hiperplan. Parametrii folositi: C=1.0 pentru regularizare L2 moderata si max_iter=1000 pentru convergenta garantata.

Random Forest

Random Forest construieste 200 de arbori de decizie, fiecare antrenat pe un subset aleatoriu al datelor si al caracteristicilor, si combina predictiile prin vot majoritar. Aceasta abordare reduce variatia fata de un singur arbore, care are tendinta sa memoreze datele de antrenare. Am ales max_depth=8 pentru a limita adancimea fiecarui arbore si a preveni overfitting-ul, in timp ce ansamblul sa poata captura relatii complexe.

Gradient Boosting

Gradient Boosting construieste arborii secvential — fiecare corecteaza erorile celui anterior prin minimizarea unei functii de pierdere. Spre deosebire de Random Forest care construieste arbori independenti in paralel, fiecare arbore nou stie ce a gresit cel precedent. Am folosit 200 de estimatori, learning_rate=0.05 si max_depth=4. Rata mica de invatare face procesul mai stabil si reduce riscul de overfitting, in schimbul unui numar mai mare de arbori necesari pentru convergenta.

5. Evaluarea modelelor

Alegerea metricilor

Cu 86% vinuri slabe in dataset, acuratetea singura nu e suficienta — un model care prezice mereu clasa 0 ar obtine 86% fara sa invete nimic util. Am ales ca metrici principale F1-Score si AUC-ROC. F1-Score este media armonica dintre precizie si recall: precizia masoara din toate vinurile prezise ca bune cate chiar sunt bune, iar recall-ul masoara din toate vinurile bune reale cate au fost identificate corect. AUC-ROC masoara capacitatea modelului de a separa cele doua clase indiferent de pragul de decizie ales, unde 1.0 ar fi perfect si 0.5 echivalent cu o clasificare aleatoare.

Rezultatele comparative

Model	Accuracy	Precision	Recall	F1-Score	AUC-ROC
Logistic Regression	0.878	0.611	0.344	0.440	0.854
Random Forest	0.908	0.739	0.531	0.618	0.917
Gradient Boosting	0.904	0.667	0.625	0.645	0.892

Regresia logistica are cel mai slab F1-Score (0.440) pentru vinurile bune. Recall-ul de 0.344 inseamna ca identifica corect doar 11 din cele 32 de vinuri bune din setul de test — mai mult de doua treimi sunt ratate. Asta confirma ca o frontiera de decizie liniara nu e suficienta pentru aceasta problema.

Random Forest imbunatateste semnificativ rezultatele: F1 = 0.618 si AUC-ROC = 0.917, cel mai bun dintre cele trei pe aceasta metrica. Gradient Boosting obtine cel mai bun F1-Score (0.645) si recall (0.625), identificand 20 din 32 de vinuri bune, dar cu mai multe false pozitive (10 fata de 6 la Random Forest). Alegerea intre cele doua depinde de context: daca vrem sa ratem cat mai putine vinuri bune, Gradient Boosting e mai bun; daca vrem sa fim mai siguri cand clasificam un vin ca bun, Random Forest are precizie mai mare (0.739 vs 0.667).

Matricele de confuzie

Figura 4 arata matricele de confuzie pentru toate trei modele pe setul de test. Clasa pozitiva (Bun) este plasata pe primul rand si prima coloana. Se observa clar ca toate modelele clasifica bine clasa majoritara (vinuri slabe), diferentele apar la clasa minoritara. Gradient Boosting identifica 20 din 32 de vinuri bune, fata de 17 pentru Random Forest si 11 pentru Logistic Regression.

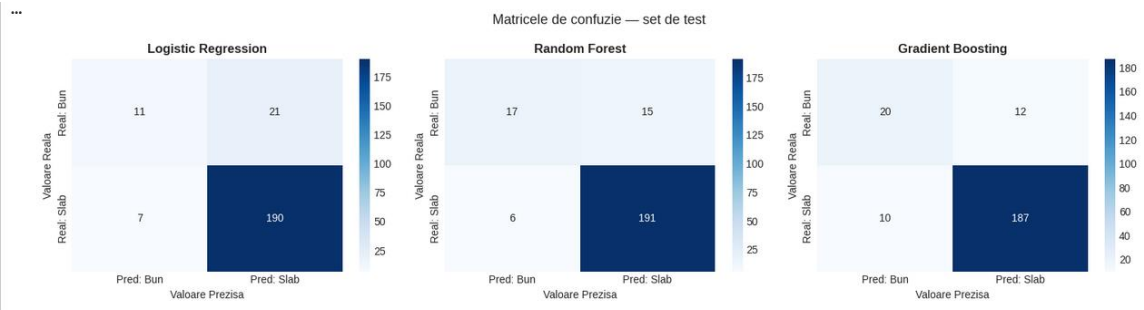


Figura 4. Matricele de confuzie pentru cele trei modele pe setul de test.

Curbele ROC

Figura 5 suprapune curbele ROC ale celor trei modele. Random Forest are aria cea mai mare sub curba (AUC = 0.917), urmat de Gradient Boosting (0.892) si Logistic Regression (0.854). Toate trei sunt net superioare clasificatorului aleatoriu. In practica, daca am vrea sa ajustam pragul de decizie sub 0.5 pentru a detecta mai multe vinuri bune in dauna preciziei, Random Forest ar oferi cel mai bun compromis.

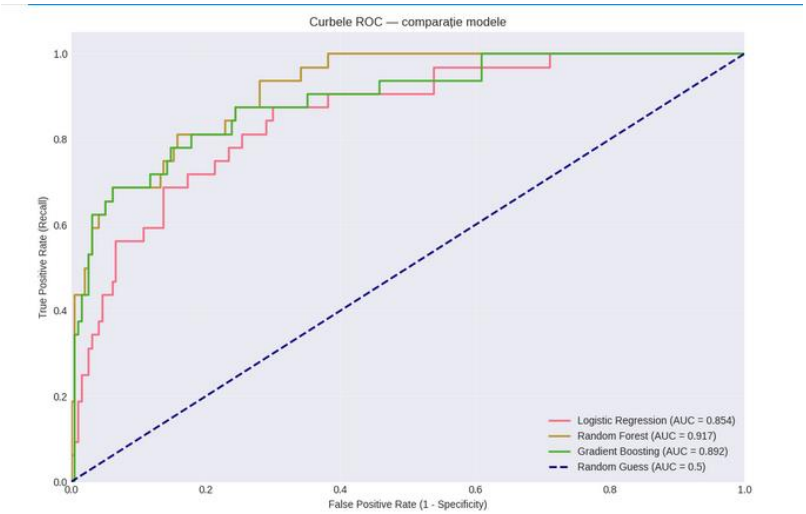


Figura 5. Curbele ROC pentru cele trei modele.

Importanta caracteristicilor

Figura 6 arata importanta fiecarei caracteristici calculata de Random Forest prin reducerea impuritatii Gini. Alcoolul e de departe cel mai important predictor, urmat de sulfati, acid citric si aciditate volatila. La polul opus, pH-ul, zaharul rezidual si clorurile contribuie cel mai putin, consistent cu corelatiile slabe observate in etapa de preprocesare.

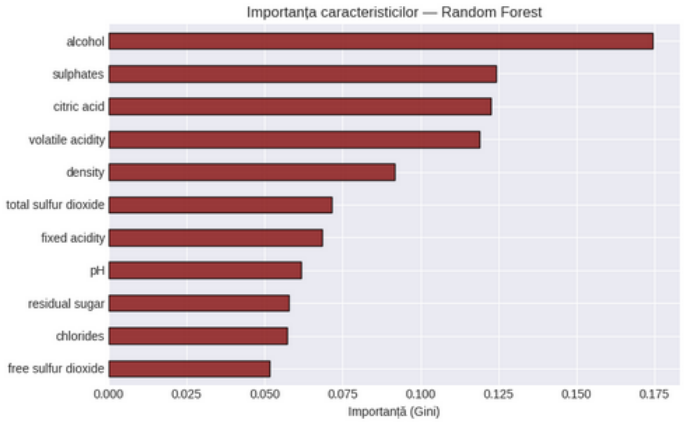


Figura 6. Importanta caracteristicilor (Gini) — Random Forest.

Validarea incrucisata

Am aplicat StratifiedKFold cu 10 fold-uri pe Gradient Boosting pentru a verifica daca rezultatele de pe setul de test sunt reprezentative. Acuratetea medie a fost 0.9015 cu o deviatie standard de 0.0223. Scorurile pe cele 10 fold-uri au variat intre 0.879 si 0.946, fara niciun fold cu performanta dramatic diferita. Variatia mica ne da incredere ca modelul este stabil si generalizeaza bine pe date nevazute.

5.7 Learning Curve

Figura 7 arata cum evolueaza eroarea (1 - F1-Score) pe masura ce crestem numarul de exemple de antrenare, pentru Logistic Regression. Cele doua curbe — eroarea pe train si eroarea pe validare — converg spre acelasi nivel si raman aproape una de alta pe tot parcursul, cu o diferenta finala de doar 0.024. Asta inseamna ca modelul nu memoreaza datele de antrenare, ci chiar invata ceva generalizabil. Valoarea erorii la final (~0.51) ramane totusi ridicata, ceea ce confirma ce am vazut si la metrici: regresia logistica pur si simplu nu e suficient de puternica pentru aceasta problema.

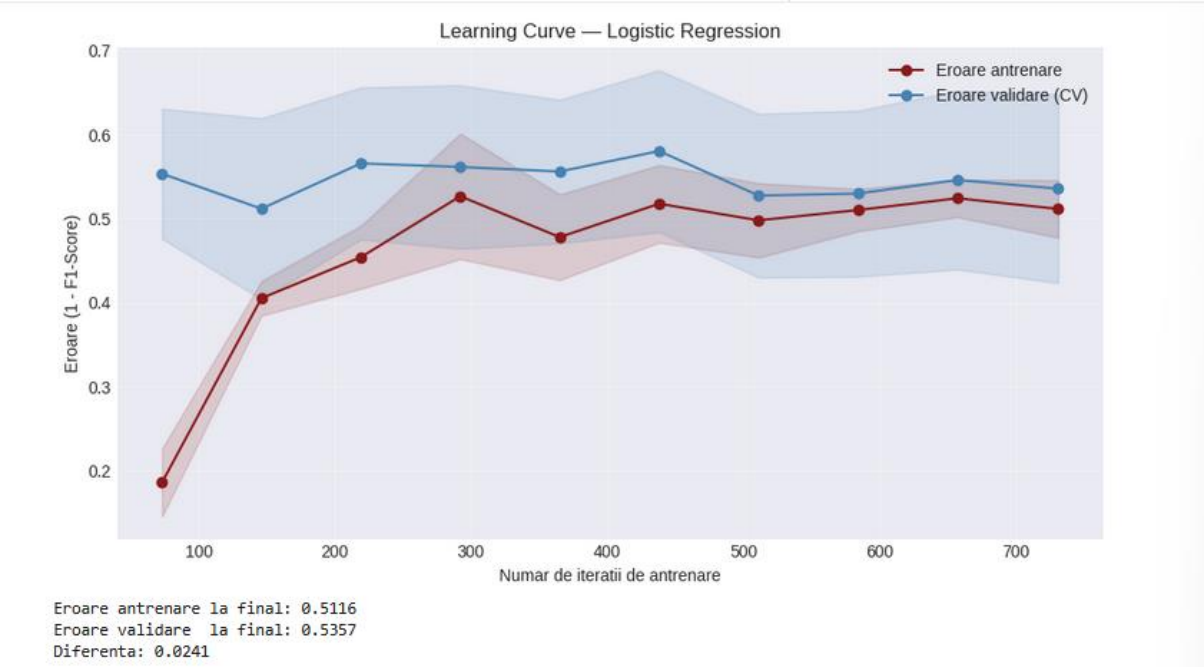


Figura 7. Learning curve

5.8 Validare pe setul de antrenare

Am vrut sa verificam si daca modelele noastre memoreaza datele de antrenare sau chiar invata ceva util, asa ca am calculat metricile si pe train, nu doar pe test. La Logistic Regression diferenta e mica — F1 pe train si pe test sunt aproape identice — ceea ce e consistent cu ce am vazut la learning curve. La Random Forest si Gradient Boosting, F1 pe train e mai mare decat pe test, ceea ce e normal pentru modele de ansamblu complexe. Important e ca diferenta nu e dramatica, iar cross-validarea a confirmat ca performanta pe date noi ramane stabila.

6. Concluzii

Modelul ales

Am ales Gradient Boosting ca model final datorita celui mai bun echilibru dintre precizie si recall pe clasa minoritara. Decizia s-a bazat in principal pe F1-Score (0.645), metrica cea mai relevanta pentru un dataset dezechilibrat. Validarea incrucisata a confirmat ca performanta este stabila si nu e un rezultat izolat al unei anumite impartiri a datelor.

Ce am invatat despre date

Cel mai important predictor pentru calitatea vinului rosu e continutul de alcool, urmat de aciditatea volatila. Asta are sens din punct de vedere chimic: un continut ridicat de alcool indica o fermentare completa a zaharurilor, iar aciditatea volatila crescuta — in special acidul acetic — e un semn clar de deteriorare a vinului. Sulfatii contribuie pozitiv, probabil pentru ca actioneaza ca un conservant natural care mentine prospetimea. Interesant e ca pH-ul si zaharul rezidual conteaza foarte putin, desi intuitiv ne-am fi asteptat ca dulceata reziduala sa influenteze mai mult perceptia calitatii.

Limitari si directii de imbunatatire

Principala problema e dezechilibrul de clase. Chiar si cu cel mai bun model, aproape 4 din 10 vinuri bune sunt clasificate gresit ca slabe. O directie concreta de imbunatatire ar fi aplicarea tehnicii SMOTE (Synthetic Minority Oversampling Technique), care genereaza exemple sintetice pentru clasa minoritara, sau ajustarea parametrului class_weight='balanced' in algoritmii de antrenare, care ar penaliza mai mult greselile pe clasa minoritara.

O alta limitare tine de datele in sine. Toate provin dintr-o singura regiune geografica (Vinho Verde, Portugalia) si dintr-o singura perioada de timp. Nu stim cat de bine ar functiona modelul pe vinuri din alte regiuni sau soiuri diferite. In fine, scorurile de calitate sunt acordate de oameni si au un grad de subiectivitate inerent — doi degustatori pot nota diferit acelasi vin, ceea ce introduce zgomot in variabila tinta pe care nu il putem controla.

Aplicatii practice

Modelul poate fi integrat in procesul de control al calitatii dintr-o crama pentru a sorta rapid loturile pe baza masuratorilor de laborator, fara a astepta degustarea. Un alt use case ar fi ghidarea procesului de fermentare: stiind ca alcoolul si aciditatea volatila sunt cei mai importanti factori, enologii pot monitoriza mai atent acesti parametri si interveni inainte ca un lot sa fie compromis.

Bibliografie

1. Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009). Modeling wine preferences by data mining from physicochemical properties. Decision Support Systems, 47(4), 547-553. https://doi.org/10.1016/j.dss.2009.05.016
2. Wine Quality Dataset — Kaggle: https://www.kaggle.com/datasets/yasserh/wine-quality-dataset
3. Moldovan, D. (2026). FBD — Statistical Learning & Machine Learning [Suport curs]. UBB Cluj-Napoca.
4. Moldovan, D. (2026). FBD — Clasificare: Logistic Regression, Naive Bayes, KNN [Suport curs]. UBB Cluj-Napoca.
5. Moldovan, D. (2026). FBD — KDD, Data Split, Decision Trees [Suport curs]. UBB Cluj-Napoca.